



Modelamiento estocástico del precio del oro mediante procesos de difusión y simulaciones Monte Carlo

Diego Yáñez Valdivia

Resumen

Se presenta el análisis estadístico de la serie de retornos logarítmicos del precio del oro (4233 observaciones diarias, 2009–2026) y la generación de simulaciones Monte Carlo mediante el modelo de **Movimiento Browniano Geométrico** (GBM). Los estadísticos descriptivos de la serie revelan una media diaria de $\bar{r} = 3,76 \times 10^{-4}$, una volatilidad de $\hat{\sigma} = 1,02 \times 10^{-2}$ y una curtosis excesiva de $\kappa = 5,20$, lo que evidencia la presencia de **colas más pesadas** que las predichas por una distribución gaussiana pura, en línea con los hallazgos de Mantegna para índices financieros [1]. A partir de estos estadísticos muestrales se obtuvieron la deriva y volatilidad del GBM ($\hat{\mu}_{\text{anual}} = 10,79\%$, $\hat{\sigma}_{\text{anual}} = 16,19\%$) y se generaron 10^5 trayectorias Monte Carlo sobre un horizonte de 252 días hábiles, con precio inicial $S_0 = 4326,65$ US\$/ozt. Los resultados muestran un precio final medio de 4819 US\$/ozt y una banda percentil 5 %–95 % entre 3649 US\$/ozt y 6200 US\$/ozt, consistente con la dispersión creciente esperada para un proceso difusivo [2].

1. Introducción

1.1. Contexto general

El precio de los activos financieros es una cantidad que evoluciona en el tiempo de manera compleja e impredecible. Su modelamiento constituye uno de los problemas centrales de la econofísica, disciplina que aplica métodos y conceptos de la física estadística al estudio de sistemas económicos y financieros [2]. En particular, los procesos de difusión han resultado especialmente útiles para describir la dinámica estocástica de precios, dado que capturan la aleatoriedad inherente a los mercados sin requerir una descripción microscópica de los agentes que los componen [2].

Una observación empírica fundamental es que los **retornos logarítmicos** de una serie de precios P_t , definidos como

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right), \quad (1)$$

presentan propiedades estadísticas que admiten una primera aproximación gaussiana. Esta observación constituye la base del modelo de **Movimiento Browniano Geométrico** (GBM), cuya ecuación diferencial estocástica es

$$dP = \mu P dt + \sigma P dW_t, \quad (2)$$

donde μ [día⁻¹] es la tasa de deriva, σ [día^{-1/2}] la volatilidad y $dW_t \sim \mathcal{N}(0, dt)$ el incremento de un proceso de Wiener. Aplicando el lema de Itô a (2) se obtiene la solución analítica

$$P(t) = P_0 \exp\left[\left(\mu - \frac{\sigma^2}{2}\right)t + \sigma W_t\right], \quad (3)$$

lo que implica que $\ln P(t)$ es un proceso gaussiano, justificando el uso de los retornos logarítmicos como estadístico central del análisis.

No obstante, Mantegna [1] demostró empíricamente que las distribuciones de retornos en mercados reales presentan **colas pesadas** (*fat tails*) y comportamiento superdifusivo, evidencia de que el GBM estándar es un modelo simplificado. Esta limitación motiva el análisis estadístico desarrollado en la sección de resultados.

En el marco de la econofísica, Mantegna y Stanley [2] establecen que herramientas de la física estadística — dinámica estocástica, autosimilaridad, escalado — permiten caracterizar sistemas económicos macroscópicos sin describir microscópicamente cada agente. Esta perspectiva justifica el enfoque adoptado, en el que el oro se modela como un sistema estocástico cuyas propiedades se estiman a partir de datos históricos.

1.2. Estado del arte y objetivo

Por otro lado, la revolución de la Inteligencia Artificial ha introducido herramientas de Aprendizaje Supervisado (Machine Learning) que prescinden de los supuestos gaussianos rígidos, permitiendo modelar relaciones no lineales complejas directamente a partir de los datos históricos. Con el propósito de efectuar una evaluación comparativa multidimensional, este trabajo incorpora dos de los algoritmos basados en ensambles de árboles de decisión más robustos y utilizados en la analítica predictiva financiera:

- **Random Forest Regressor (Bosques Aleatorios):** Este método se fundamenta en el principio de *Bagging* (Bootstrap Aggregating). Construye de manera paralela un gran conjunto de árboles de decisión independientes, donde cada árbol se entrena con una submuestra aleatoria de los datos y un subconjunto aleatorio de las características financieras (como rezagos de precios, volatilidad móvil o indicadores técnicos). La predicción final del modelo corresponde al promedio de las predicciones de todos los árboles individuales, lo que reduce drásticamente la varianza del error y protege al modelo contra el sobreajuste (overfitting).
- **XGBoost Regressor (Extreme Gradient Boosting):** A diferencia del enfoque en paralelo de Random Forest, XGBoost opera bajo el principio de *Boosting* (Potenciación). Construye árboles de decisión de forma secuencial y aditiva, donde cada nuevo árbol se entrena específicamente para minimizar una función de pérdida regularizada mediante el gradiente descendiente, corrigiendo de manera explícita los errores residuales cometidos por los árboles predecesores. Es un algoritmo altamente eficiente y valorado en la optimización de portafolios por su capacidad para capturar patrones secuenciales abruptos y manejar estructuras de datos con alta curtosis.

El objetivo central de esta investigación evoluciona, por lo tanto, hacia un análisis comparativo directo de tres vertientes metodológicas bien

diferenciadas: un enfoque estocástico difusivo puro (*Geometric Brownian Motion*), un enfoque de ensamble por promediado probabilístico (*Random Forest*) y un enfoque de optimización secuencial por gradiente (*XGBoost*). Esta triple comparativa, que se consolidará en la etapa final del proyecto, busca evaluar no solo la precisión puntual de las predicciones del precio del oro en un horizonte temporal determinado, sino también la capacidad de cada metodología para replicar propiedades estadísticas complejas de la serie real, tales como la asimetría y el comportamiento de las colas pesadas.

1.3. Introducción teórica de la estadística utilizada

Para caracterizar el comportamiento de un activo financiero sin requerir un trasfondo avanzado en procesos estocásticos, es fundamental definir un conjunto de métricas estadísticas descriptivas que operan como los pilares analíticos de este informe. Estas herramientas permiten transformar una masa de datos crudos en indicadores cinemáticos de la dinámica del mercado.

En primer lugar, dada una muestra de retornos logarítmicos r_t de tamaño N , la **media muestral** ($\bar{r}$) representa el retorno esperado por unidad de tiempo y se define matemáticamente como:

$$\bar{r} = \frac{1}{N} \sum_{t=1}^N r_t \quad (4)$$

En términos generales, este número nos indica la dirección neta del movimiento del precio; un valor positivo traduce una tendencia alcista estructural a lo largo del periodo muestreado. Para nuestro estudio del oro, la media es el componente que determina el desplazamiento horizontal (la deriva) de nuestras proyecciones.

La dispersión o el grado de incertidumbre de estos retornos alrededor de su promedio se cuantifica mediante la **varianza muestral** (s^2) y su raíz cuadrada, la **desviación estándar muestral** (s):

$$s^2 = \frac{1}{N-1} \sum_{t=1}^N (r_t - \bar{r})^2 \quad (5)$$

En el ecosistema financiero, la desviación estándar



dar de los retornos se denomina formalmente **volatilidad**. Físicamente representa la intensidad del proceso de difusión: a mayor volatilidad, el abanico de precios posibles en el futuro se ensancha de manera más agresiva, incrementando el riesgo del activo.

Para evaluar la morfología de la distribución de probabilidad de los datos en comparación con una distribución Normal ideal (gaussiana), se utilizan los momentos estadísticos de orden superior. El primero de ellos es la **asimetría** (γ_1), que mide la falta de simetría de la distribución respecto a su media:

$$\gamma_1 = \frac{\frac{1}{N} \sum_{t=1}^N (r_t - \bar{r})^3}{\left[\frac{1}{N} \sum_{t=1}^N (r_t - \bar{r})^2 \right]^{3/2}} \quad (6)$$

Un $\gamma_1 = 0$ denota simetría perfecta. Un valor negativo indica que la distribución está sesgada hacia la izquierda, manifestando que los retornos negativos extremos son más probables o severos que los positivos. En el caso del oro, nos permite identificar si el mercado es propenso a sufrir caídas abruptas a pesar de su tendencia general alcista.

Por su parte, la **curtosis excesiva** (κ) evalúa el grosor de las colas de la distribución, es decir, la frecuencia con la que ocurren eventos muy alejados de la media, y se define como:

$$\kappa = \frac{\frac{1}{N} \sum_{t=1}^N (r_t - \bar{r})^4}{\left[\frac{1}{N} \sum_{t=1}^N (r_t - \bar{r})^2 \right]^2} - 3 \quad (7)$$

El factor -3 asegura que una distribución Normal perfecta posea $\kappa = 0$. Si $\kappa > 0$, la distribución se denomina *leptocúrtica*, lo que significa matemáticamente que los valores extremos (cisnes negros.^o crisis de mercado) se presentan con una frecuencia significativamente mayor a la anticipada por una campana de Gauss tradicional.

Finalmente, para examinar si los retornos de un día guardan relación con los retornos de días previos, se utiliza la **función de autocorrelación** $\rho(\tau)$ para un retardo temporal τ :

$$\rho(\tau) = \frac{\sum_{t=\tau+1}^N (r_t - \bar{r})(r_{t-\tau} - \bar{r})}{\sum_{t=1}^N (r_t - \bar{r})^2} \quad (8)$$

Este estadístico oscila estrictamente entre -1 y 1 . Un valor cercano a cero para cualquier retardo implica que los retornos pasados no contienen información linealmente útil para predecir los retornos futuros, cumpliendo así el principio de eficiencia de mercado e incrementos independientes indispensable para validar el uso matemático del proceso de Wiener en el GBM.

2. Metodología

El proyecto se implementa como un *pipeline* computacional en Python 3, organizado en cuatro scripts independientes y reproducibles. El repositorio (de momento) tiene la siguiente estructura:

```
gold-price-stochastic-model/
  preprocess_data.py
  compute_returns.py
  analyze_returns.py
  simulate_gbm.py
  data/
    raw/
    processed/
      gold_prices_clean.csv
      gold_returns.csv
  outputs/
```

La separación entre `data/raw/`, `data/processed/` y `outputs/` es metodológicamente relevante: permite distinguir entre datos originales, datos transformados y resultados derivados, garantizando la trazabilidad del análisis.

2.1. Adquisición y preprocesamiento de datos

Se recopilaron los precios históricos diarios del oro en US\$/ozt desde registros públicos del Banco Central de Chile. Los datos originales se distribuyen en múltiples archivos anuales, consolidados por `preprocess_data.py` mediante las siguientes operaciones: lectura de los archivos originales con `pandas` según el formato provisto por la fuente, concatenación de los *DataFrames* individuales en una única serie temporal, conversión de fechas a `datetime64` con `pandas.to_datetime()`, eliminación de valores faltantes con `dropna()` y ordenamiento cronológico ascendente. El producto es el archivo `gold_prices_clean.csv`, que contiene la serie limpia $\{P_t\}$ con columnas [Fecha, Precio].



2.2. Construcción de retornos logarítmicos

El script `compute_returns.py` toma `gold_prices_clean.csv` y calcula la serie $\{r_t\}$ mediante la expresión (1), implementada como operación vectorizada con `numpy.log()` y `pandas.Series.diff()`. Los retornos son adimensionales porque el cociente P_t/P_{t-1} cancela las unidades [US\$/ozt]. El producto es `gold_returns.csv`, con columnas [Fecha, Precio, Return], que constituye la base para las etapas siguientes. Bajo el GBM, los retornos satisfacen

$$r_t \sim \mathcal{N}\left(\left(\mu - \frac{\sigma^2}{2}\right) \Delta t, \sigma^2 \Delta t\right), \quad (9)$$

con $\Delta t = 1$ día, lo que permite estimar μ y σ directamente desde los estadísticos de la serie.

2.3. Análisis estadístico de retornos y estimación de parámetros

El script `analyze_returns.py` carga `gold_returns.csv`, normaliza los nombres de columna a [date, price, log_return], convierte las fechas a tipo temporal y elimina registros inválidos. A continuación calcula los estadísticos descriptivos de $\{r_t\}$ mediante métodos integrados de `pandas`, genera las visualizaciones de la distribución y la autocorrelación, y estima los parámetros del GBM. Los estadísticos muestrales utilizados, derivados de la distribución (9), son

$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{t=1}^N (r_t - \bar{r})^2, \quad (10)$$

$$\hat{\mu}_{\text{diario}} = \bar{r} + \frac{\hat{\sigma}^2}{2}, \quad (11)$$

con $\bar{r} = N^{-1} \sum r_t$. La expresión (11) surge de identificar $\bar{r} \approx (\mu - \sigma^2/2)\Delta t$ según (9) con $\Delta t = 1$ día, de modo que $\hat{\mu}$ incorpora la corrección de convexidad $+\hat{\sigma}^2/2$ propia del GBM. Los parámetros anualizados se obtienen como

$$\hat{\mu}_{\text{anual}} = 252 \hat{\mu}_{\text{diario}}, \quad \hat{\sigma}_{\text{anual}} = \sqrt{252} \hat{\sigma}_{\text{diario}}, \quad (12)$$

donde el factor 252 corresponde al número convencional de días hábiles bursátiles por año. Los parámetros diarios se usan en la simulación; los anualizados, para interpretación.

2.4. Simulación Monte Carlo mediante GBM

El script `simulate_gbm.py` carga `gold_returns.csv` y `gbm_parameters.csv`, toma como precio inicial S_0 el último valor observado en la serie histórica y genera $M = 10^5$ trayectorias sintéticas mediante la discretización exacta de (3):

$$S_{t+1} = S_t \exp\left[\left(\hat{\mu} - \frac{\hat{\sigma}^2}{2}\right) \Delta t + \hat{\sigma} \sqrt{\Delta t} Z_t\right], \quad (13)$$

donde $Z_t \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$, generados con `numpy.random.normal()`. La simulación se vectoriza sobre las M trayectorias operando sobre matrices de `numpy`, lo que evita bucles explícitos. El horizonte de simulación es $T = 252$ días hábiles ($\Delta t = 1$). Dado que el almacenamiento de $10^5 \times 252$ trayectorias crudas genera un archivo de ≈ 436 MB, el script guarda únicamente el resumen estadístico en `gbm_simulation_summary.csv`.

3. Resultados y análisis

3.1. Serie temporal del precio del oro

La figura 1 muestra la evolución del precio del oro en US\$/ozt desde 2009 hasta 2026. La serie exhibe tres fases cualitativamente distintas: una fase alcista pronunciada entre 2009 y 2012, que eleva el precio desde ≈ 900 US\$/ozt hasta un máximo local de ≈ 1900 US\$/ozt; una fase de consoli-

dación y corrección entre 2013 y 2019, con precios entre 1050 y 1350 US\$/ozt; y una segunda fase alcista intensa desde 2020, con aceleración marcada a partir de 2024 que lleva el precio hasta ≈ 4500 US\$/ozt al cierre de la serie. Esta dinámica no estacionaria en el nivel de precios justifica el uso de retornos logarítmicos en lugar de precios absolutos para el análisis estadístico.




Figura 1: Serie temporal del precio del oro en US\$/ozt para el período 2009–2026 ($N = 4233$ observaciones diarias).

3.2. Serie de retornos logarítmicos

La figura 2 presenta la serie temporal de retornos logarítmicos diarios $\{r_t\}$. A diferencia de la serie de precios, los retornos fluctúan alrededor de un valor medio cercano a cero sin tendencia apreciable, lo que es consistente con la hipótesis de estacionariedad débil del GBM. Se observan episodios de alta volatilidad agrupada (*volatility clustering*) — particularmente visibles en torno a 2013, 2020 y 2025 — que sugieren la presencia de heterocedasticidad en la serie, una característica documentada en series financieras reales [2] y que el GBM estándar con volatilidad constante no modela.




Figura 2: Serie temporal de retornos logarítmicos diarios $\{r_t\}$ (adimensional). Se observan episodios de volatilidad agrupada.

3.3. Estadísticos descriptivos

La tabla 1 resume los estadísticos descriptivos de la serie $\{r_t\}$, calculados a partir de $N = 4233$ observaciones.

Tabla 1: Estadísticos descriptivos de la serie de retornos logarítmicos diarios. Los retornos son adimensionales.

Estadístico	Símbolo	Valor
Número de observaciones	N	4 233
Media	$\bar{r}$	$3,762 \times 10^{-4}$
Varianza	s^2	$1,040 \times 10^{-4}$
Desviación estándar	s	$1,020 \times 10^{-2}$
Asimetría	γ_1	$-0,417$
Curtosis excesiva	κ	5,197
Mínimo	$r_{\min}$	$-9,596 \times 10^{-2}$
Máximo	$r_{\max}$	$6,841 \times 10^{-2}$

Los resultados de la tabla 1 revelan aspectos relevantes sobre la validez del GBM para esta serie. La media diaria $\bar{r} = 3,76 \times 10^{-4}$ es positiva y de magnitud pequeña, coherente con la tendencia alcista de largo plazo observada en la figura 1. La volatilidad diaria $s = 1,02\%$ corresponde a una volatilidad anualizada de $\hat{\sigma}_{\text{anual}} = 16,19\%$, valor típico para el mercado del oro.

El estadístico más informativo para evaluar el supuesto de normalidad es la **curtosis excesiva** $\kappa = 5,20$. Bajo una distribución gaussiana se espera $\kappa = 0$; el valor observado es positivo y significativamente distinto de cero, lo que indica que la distribución empírica presenta un pico más pronunciado y colas más pesadas que la normal. Este fenómeno — denominado *leptocurtosis* — implica que los eventos extremos (retornos $|r_t| \gg s$) ocurren con mayor frecuencia de la predicha por el GBM. Este resultado es cuantitativamente coherente con los hallazgos de Mantegna [1], quien documentó curtosis elevadas en índices bursátiles y las atribuyó a la presencia de paseos de Lévy en lugar de difusión gaussiana simple. La asimetría $\gamma_1 = -0,417$ indica además una ligera inclinación hacia retornos negativos extremos, observable en el retorno mínimo ($r_{\min} = -9,6\%$) mayor en magnitud que el máximo ($r_{\max} = 6,8\%$).

3.4. Distribución empírica y comparación con la gaussiana

La figura 3 superpone el histograma de $\{r_t\}$ con la distribución normal ajustada con parámetros $(\bar{r}, s)$. La discrepancia entre ambas es visible en dos aspectos. En primer lugar, el pico central

del histograma excede considerablemente la altura máxima de la curva normal (≈ 60 vs. ≈ 39 en escala de densidad de probabilidad), confirmando la leptocurtosis reportada en la tabla 1. En segundo lugar, la distribución empírica muestra colas más largas: se observan retornos en el rango $[-0,10, -0,050]$ y $[0,050, 0,075]$ con densidad no nula, mientras que la curva normal ajustada asigna probabilidad prácticamente nula a esos valores. Esta discrepancia constituye la principal limitación del GBM estándar aplicado a esta serie: al suponer retornos gaussianos, el modelo asigna menor probabilidad a eventos extremos que los observados empíricamente. En consecuencia, las distribuciones de retornos simulados tenderán a ser más estrechas en las colas que la distribución real, aunque el impacto concreto sobre la distribución de precios finales depende de la magnitud relativa de esas discrepancias y se evaluará cuantitativamente en la etapa de comparación.




Figura 3: Histograma de retornos logarítmicos diarios con distribución normal ajustada ($\bar{r}$, s) superpuesta. Se observa leptocurtosis y colas empíricas más pesadas que las gaussianas.

3.5. Autocorrelación de retornos

La figura 4 muestra la función de autocorrelación $\rho(\tau)$ de $\{r_t\}$ para retardos $\tau = 1, \dots, 30$ días, definida por (8). El umbral de significancia estadística al 95 % para una serie de $N = 4233$ observaciones es $\pm 1,96/\sqrt{N} = \pm 0,030$. De los 30 rezagos evaluados, la mayoría presenta valores de $|\rho(\tau)| < 0,030$, lo que es consistente con la hipótesis de independencia de los incrementos del GBM [2]. Se observan dos rezagos con valores ligera-

mente por encima del umbral: $\tau = 5$ ($\rho \approx 0,033$) y $\tau = 12$ ($\rho \approx 0,032$), ambos en la dirección positiva. Dada su pequeña magnitud y la ausencia de un patrón estructural coherente, estos valores no constituyen evidencia robusta de dependencia temporal en los retornos. El resultado es globalmente favorable al supuesto de independencia del GBM, aunque no lo confirma de manera definitiva.




Figura 4: Función de autocorrelación $\rho(\tau)$ de retornos logarítmicos para $\tau = 1, \dots, 30$ días. La línea azul indica $\rho = 0$. El umbral de significancia al 95 % es $\pm 0,030$ (líneas $\pm 1,96/\sqrt{N}$, no graficadas; véase el análisis en el texto).

3.6. Parámetros estimados del GBM

La tabla 3.6 reporta los parámetros del GBM estimados a partir de la serie de retornos, aplicando las ecuaciones (10), (11) y (12).

Parámetro	Descripción	Valor diario	Valor anualizado
$\hat{\mu}$	Tasa de deriva	$4,282 \times 10^{-4} \text{ día}^{-1}$	16,72 %
$\hat{\sigma}$	Volatilidad	$1,020 \times 10^{-2} \text{ día}^{-1/2}$	16,72 %

Tabla 2: Parámetros del GBM estimados desde la serie histórica de retornos logarítmicos. Los parámetros anualizados se calculan con factor 252 días hábiles.

La deriva anualizada $\hat{\mu}_{\text{anual}} = 10,79\%$ representa el crecimiento promedio esperado del precio del oro bajo el modelo, estimado sobre el período histórico analizado e incorporando la corrección



de convexidad $+\hat{\sigma}^2/2$ propia del GBM. La volatilidad anualizada $\hat{\sigma}_{\text{anual}} = 16,19\%$ cuantifica la escala típica de las fluctuaciones; la volatilidad anualizada permite expresar la escala de fluctuación diaria en una escala temporal anual, facilitando la interpretación del parámetro de difusión. Es importante destacar que estos parámetros se mantienen constantes durante toda la simulación, lo que constituye un supuesto simplificador del GBM estándar que no captura la heterocedasticidad visible en la figura 2.

3.7. Simulación Monte Carlo: trayectorias

La figura 5 muestra un subconjunto representativo de las $M = 10^5$ trayectorias simuladas mediante la ecuación (13), partiendo desde $S_0 = 4326,65$ US\$/ozt. Se observa el comportamiento esperado de un proceso GBM: todas las trayectorias parten del mismo precio inicial, la dispersión del conjunto crece con el tiempo y el precio permanece estrictamente positivo en todas las realizaciones, propiedad garantizada por la forma exponencial de (3).




Figura 5: Subconjunto de trayectorias Monte Carlo simuladas mediante GBM a lo largo de $T = 252$ días hábiles desde $S_0 = 4326,65$ US\$/ozt.

3.8. Trayectoria media y banda de incertidumbre

La figura 6 presenta la trayectoria media del conjunto de simulaciones junto con la **banda percentil predictiva 5 %-95 %**, que delimita el intervalo dentro del cual cae el 90 % de las trayectorias simuladas y cuantifica la dispersión acumulada del proceso. La trayectoria media asciende suavemente desde 4327 US\$/ozt has-

ta ≈ 4819 US\$/ozt al cabo de 252 días, reflejando la deriva positiva $\hat{\mu} > 0$. La banda predictiva es asimétrica y se ensancha con el tiempo: al día $t = 252$, el percentil 95 alcanza ≈ 6200 US\$/ozt y el percentil 5 desciende hasta ≈ 3649 US\$/ozt, con una amplitud total de ≈ 2551 US\$/ozt. Esta asimetría es característica de los procesos log-normales y se origina en la solución exponencial (3): los precios pueden crecer sin cota superior pero no pueden volverse negativos, lo que desplaza la distribución hacia valores positivos [2].




Figura 6: Trayectoria media (línea sólida) y banda percentil predictiva 5 %-95 % (área sombreada) de las $M = 10^5$ simulaciones GBM a lo largo de $T = 252$ días hábiles.

3.9. Distribución de precios finales

La figura 7 muestra la distribución de los precios finales $\{S^{(k)}(T)\}_{k=1}^M$ al término de las 10^5 simulaciones. La tabla 3.9 resume los estadísticos del precio final.

Estadístico	Valor [US\$/ozt]
Precio inicial S_0	4 326,65
Media de precios finales	4 818,7
Desviación estándar	783,5
Percentil 5	3 648,8
Percentil 50 (mediana)	4 755,6
Percentil 95	6 199,9
Precio mínimo simulado	2 033,3
Precio máximo simulado	9 282,7

Tabla 3: Resumen estadístico de los precios finales simulados ($T = 252$ días, $M = 10^5$ trayectorias). Precios en US\$/ozt.

La distribución de precios finales es aproxi-

madamente log-normal, con una asimetría positiva visible: la media (4819 US\$/ozt) supera a la mediana (4756 US\$/ozt), lo que es consistente con la propiedad teórica del GBM según la cual $\mathbb{E}[P(t)] = P_0 e^{\mu t} > P_0 e^{(\mu - \sigma^2/2)t}$ (mediana teórica). Esta forma log-normal es una consecuencia directa de la solución (3).




Figura 7: Distribución de precios finales simulados al día $T = 252$. La forma asimétrica positiva es consistente con la distribución log-normal del GBM.

Referencias

- [1] Mantegna, R. N. (1991). Lévy walks and enhanced diffusion in Milan stock exchange. *Physica A: Statistical Mechanics and its Applications*, 179(2), 232–242.
- [2] Mantegna, R. N., & Stanley, H. E. (1999). *An introduction to econophysics: Correlations and complexity in finance*. Cambridge University Press.

4. Conclusión

El análisis estadístico de la serie histórica del precio del oro confirma que los retornos logarítmicos presentan media y autocorrelación próximas a cero, pero exhiben una curtosis excesiva $\kappa = 5,20$ incompatible con el supuesto gaussiano del GBM estándar. Este resultado es coherente con los hallazgos de Mantegna [1] y constituye la principal limitación del modelo adoptado. Los estadísticos muestrales obtenidos ($\hat{\mu}_{\text{anual}} = 10,79\%$, $\hat{\sigma}_{\text{anual}} = 16,19\%$) alimentan una simulación Monte Carlo de 10^5 trayectorias sobre un año hábil, cuyos resultados son cualitativamente consistentes con las propiedades teóricas del GBM: positividad de los precios, dispersión creciente y distribución final aproximadamente log-normal.

Quedan pendientes para el informe final las siguientes tareas: (i) la comparación cuantitativa entre la distribución de retornos simulados y la distribución empírica, mediante estadísticos de bondad de ajuste como la prueba de Kolmogórov-Smirnov; (ii) la evaluación del escalado de la varianza empírica $\langle(\Delta P)^2\rangle$ en función del tiempo, para contrastar difusión normal frente a comportamiento superdifusivo; y (iii) la incorporación de las bandas de significancia $\pm 1,96/\sqrt{N}$ directamente en la figura de autocorrelación.